暑期“五个一”素质提升活动论文

基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱

学　　号：2020202184

专　　业：应用化学（03）

姓　　名：黄文杰

日　　期：2021 年 8 月

摘要

现如今互联网技术发展迅猛，网络上的信息层出不穷，令人眼花缭乱。如何从大量的信息中准确地、快速地、便捷地获取到自己所需要的信息便成为一个值得令人思考的问题。对于我们大学生来说，每个人都离不开学校教务处发布的通知，选课、放假安排、期末考试安排、竞赛活动通知等等都由学校教务处发布，而许多人也都想第一时间获取到放假安排等通知。本文利用 Python 网络爬虫等相关知识，基于 GitHub Actions，一个能够自动完成软件开发周期内的任务，并在指定事件发生后运行一系列命令的持续集成服务，来实现定时爬取青岛大学教务通知及教学动态并将所爬取到的信息发送至目标邮箱。

关键词：Python 网络爬虫；GitHub Actions；教务通知；定时邮件

Abstract

Nowadays, with the rapid development of Internet technology, the information on the network is endless and dazzling. How to accurately, quickly and conveniently obtain the information they need from a large amount of information has become a problem worthy of consideration. For our college students, everyone is inseparable from the notice issued by the Academic Affairs Office of the school. The notice of course selection, holiday arrangement, final examination arrangement, competition activities, etc. are issued by the Academic Affairs Office of the school, and many people want to get the notice of holiday arrangement at the first time. This paper uses Python web crawler and other related knowledge, based on GitHub actions, a continuous integration service that can automatically complete the tasks in the software development cycle and run a series of commands after the specified event, so as to regularly crawl the educational administration notice and teaching dynamics of Qingdao University, and send the crawled information to the target mailbox.

Keywords: Python Web Crawler; GitHub Actions; Educational administration notice; Scheduled mail

目录

第一章 前言 1
1.1 设计背景与设计意义 1
1.1.1 设计背景 1
1.1.2 设计意义 1
1.2 设计思路 1
第二章 爬虫代码 2
2.1 爬取青岛大学教务通知（教学动态）源码 2
2.1.1 导入所需要用到的库 2
2.1.2 获取源码 2
2.2 解析源码并提取所需信息 3
2.3 判断所提取的教务通知是否为当天或前一天发布 3
2.4 完整代码 4
第三章 定时发送邮件 5
3.1 编写.yml 文件以实现定时运行爬虫代码并发送邮件 5
3.1.1 配置执行时间 5
3.1.2 配置系统 5
3.1.3 安装环境 5
3.1.4 设计发送邮件机制 6
3.1.5 完整代码 7
第四章 提交代码 8
4.1 将所有代码提交至仓库等待运行 8
4.2 运行界面 8
4.3 运行后效果 9
第五章 总结与展望 11
参考文献 12

第一章 前言

1.1 设计背景与设计意义

1.1.1 设计背景

信息技术自诞生以来就一直保持着高速发展的态势，互联网技术的发展让人与人之间的关系更加紧密。随着时间的推移，网络中的数据变得越来越繁杂，信息过载的问题变得愈加严重。如何在海量的数据中获取对自己有用的信息成为了人们关注的问题[1]。基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱服务就是为了解决这种问题而设计的。

1.1.2 设计意义

基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱服务能够从繁杂的网络数据中中准确地、快速地、便捷地获取到自己所需要的信息，妈妈再也不用担心我错过学校教务通知了。

1.2 设计思路

首先需要编写一套能够爬取青岛大学教务网站信息的代码，接着对获取到的源码进行分析，提取出所需要的信息，再判断所提取的信息是否具有时效性（是否为当天或前一天发布）。然后将 GitHub Actions 作为定时运行爬虫代码的载体，将爬取下来的信息发送至目标邮箱。

第二章 爬虫代码

2.1 爬取青岛大学教务通知（教学动态）源码

2.1.1 导入所需要用到的库

```
import requests
from lxml import etree
import datetime
```

图 2.1 所需第三方库

基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱服务需要用到三个第三方库。

Requests 库，Requests 是一个优雅而简单的 Python HTTP 库，这里我们只用到 requests.get()函数，通过此函数可以获取网页的源代码。

lxml 库，是 python 的一个解析库,支持 HTML 和 XML 的解析,支持 XPath 解析方式,而且解析效率非常高，这里用 etree.HTML()函数来解析 html 源码。

Datetime 库，datetime 是一个关于时间的库，这里用来获取代码运行时的系统时间，达到判断是否具有时效性的目的。

2.1.2 获取源码

```
if __name__ == '__main__':
#青岛大学教务处教务通知
    url = 'http://jw.qdu.edu.cn/homepage/infoArticleList.do;jsessionid=D7477658C10DEA783A4FB0410A47904D?columnId=358'

    response = requests.get(url, headers={
            'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/72.0.3626.96 Safari/537.36'})
    response.encoding = response.apparent_encoding
    html = response.text
```

图 2.2 获取 HTML 源代码

利用 requests.get()函数获取目标 URL 的源代码，其中添加 headers 请求头的原因是为了反反爬虫，防止服务器识别为爬虫进而拒绝访问。

其中 response.encoding = response.apparent_encoding()是为了修正编码，能够正常显示中文字符。

2.2 解析源码并提取所需信息

```
parser = etree.HTML(html)


titles = parser.xpath('//a[@target="_blank"]/text()')
title = []
for i in titles:
    for j in ['\r','\n',' ']:
        i = i.replace(j,'')
    title.append(i)


names = []
for i in title:
    if len(i) ==0:
        continue
    names.append(i)
names = names[:-1]


times = parser.xpath('//span/text()')
times = times[2:-2]


link = parser.xpath('//a[@target="_blank"]/@href')[:-1]
links = []
for i in link:
    links.append('http://jw.qdu.edu.cn/homepage/' + i)
```

图 2.3 解析 HTML 源代码并提取信息

依据信息在网页源代码中的分布，利用 xpath 方法提取所需要的信息。信息结构组成包括 title，即通知类别，分为教务通知和教学动态两大类；names，即通知标题；links，即通知链接，通过阅读通知标题来判断是否需要查看具体通知内容。

2.3 判断所提取的教务通知是否为当天或前一天发布

```
today = datetime.datetime.now()
    # 计算偏移量
offset = datetime.timedelta(days=-1)
    # 获取想要的日期的时间
yesterday = (today + offset).strftime('%Y-%m-%d')
today = datetime.datetime.now().strftime('%Y-%m-%d')
with open("./text.html", "w", encoding="utf-8") as f:
    if times[0] == today or times[0] == yesterday:
        news = "今日更新内容 :" + '\n' + '青岛大学教务处教务通知:' + names[0] + ',' + times[0] + ',' + links[0]
        f.write(news)
        f.write('\n')
    else:
        f.write('今天没有新的教务通知哦')
        f.write('\n')
```

图 2.4 判断时效性

通过 datetime 库获取当前系统时间，与爬取的第一条通知时间进行比较，若具有时效性（通知为当天或前一天发布），则将通知发送至目标邮箱；若不具有时效性，则发送“今

天没有新的教务通知哦”至目标邮箱。

2.4 完整代码

```python
# coding=utf-8
import requests
from lxml import etree
import datetime
today = datetime.datetime.now()
        # 计算偏移量
offset = datetime.timedelta(days=-1)
        # 获取想要的日期的时间
yesterday = (today + offset).strftime('%Y-%m-%d')
today = datetime.datetime.now().strftime('%Y-%m-%d')


if __name__ == '__main__':
#青岛大学教务处教务通知
    url = 'http://jw.qdu.edu.cn/homepage/infoArticleList.do;jsessionid=D7477658C10DEA783A4FB0410A47904D?columnId=358'

    response = requests.get(url, headers={
            'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/72.0.3626.96 Safari/537.36'})
    response.encoding = response.apparent_encoding
    html = response.text
    parser = etree.HTML(html)


    titles = parser.xpath('//a[@target="_blank"]/text()')
    title = []
    for i in titles:
        for j in ['\r','\n',' ']:
            i = i.replace(j,'')
        title.append(i)


    names = []
    for i in title:
        if len(i) ==0:
            continue
        names.append(i)
    names = names[:-1]


    times = parser.xpath('//span/text()')
    times = times[2:-2]


    link = parser.xpath('//a[@target="_blank"]/@href')[:-1]
    links = []
    for i in link:
        links.append('http://jw.qdu.edu.cn/homepage/' + i)


    with open("./text.html", "w", encoding="utf-8") as f:
        if times[0] == today or times[0] == yesterday:
            news = "今日更新内容 :" + '\n' + '青岛大学教务处教务通知:' + names[0] + ',' + times[0] + ',' + links[0]
            f.write(news)
            f.write('\n')
        else:
            f.write('今天没有新的教务通知哦')
            f.write('\n')
```

图 2.5 完整代码

第三章 定时发送邮件

3.1 编写 action.yml 文件以实现定时运行爬虫代码并发送邮件

3.1.1 配置执行时间

```yaml
on:
  push:
  schedule:
    - cron: '0 22 * * *'
```

图 3.1 配置执行时间

这里的 on 表示执行的时间，比如我这里是每次 push 之后和每天的 22 点（国际时间，换成北京时间是早上 6 点)执行，schedule 的设置遵循 POSIX cron 语法。

3.1.2 配置系统

```yaml
jobs:
  build:
    runs-on: ubuntu-latest

    steps:
    - uses: actions/checkout@v2
      with:
        presist-credentials: false
        fetch-depth: 0
```

图 3.2 配置系统

这里表示运行的系统为 ubuntu 最新版。

3.1.3 安装环境

```yaml
    - name: Set up Python 3.8
      uses: actions/setup-python@v2
      with:
        python-version: '3.8'
    - name: Install dependencies
      run: |
        python -m pip install --upgrade pip
        pip install -r ./requirements.txt
    - name: Run my script
      run: |
        python ./my_script.py
```

图 3.3 安装环境

这里表示安装的 python 版本是 3.8，然后安装根目录下的依赖（比如爬虫中的 requests 和 lxml，自己是不带的，需要在运行机里 pip 安装）

3.1.4 设计发送邮件机制

```yaml
- name: 'Send mail'
  uses: dawidd6/action-send-mail@master
  with:
    server_address: smtp.qq.com
    server_port: 465
    username: ${{ secrets.MAIL_USERNAME }}
    password: ${{ secrets.MAIL_PASSWORD }}
    subject: 来自onlyourmiracle的news每日通知快送

    body: file://text.html
    to: ${{ secrets.MAIL_LIST }}
    from: GitHub Actions
    content_type: text/html
```

图 3.4 发送邮件机制

这里是发送邮件的机制,用的是 qq 邮箱，其中需要在当前仓库 Settings 下的 Secrets 中添加个人隐私信息

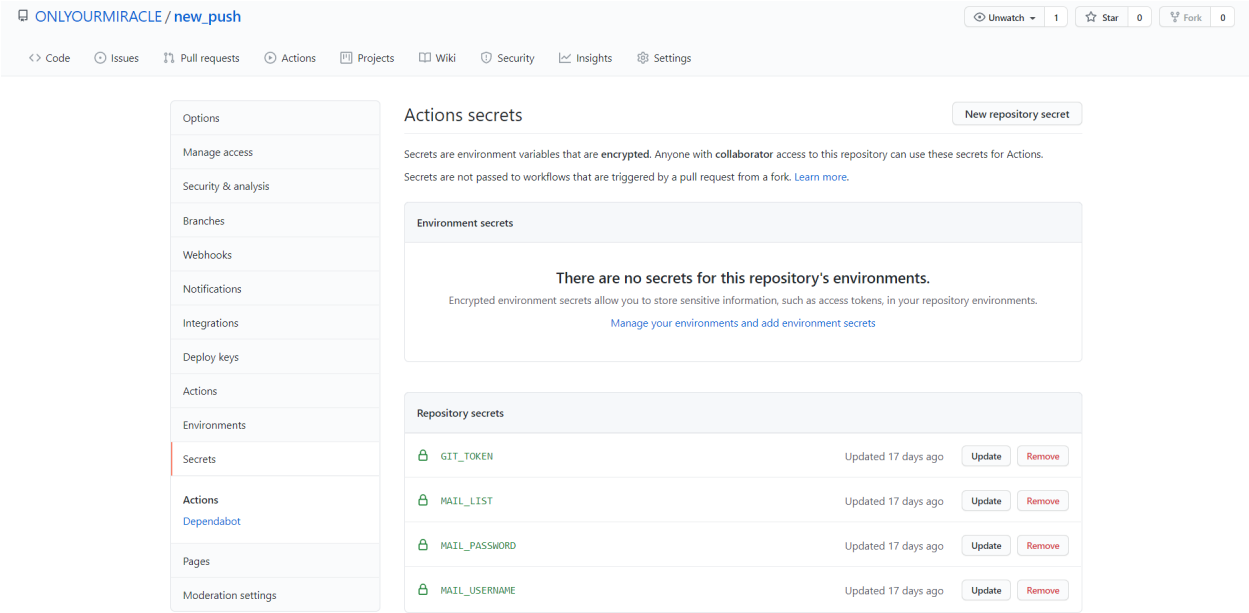

图 3.5 添加个人隐私信息

因为 Github 仓库是开源的，将个人隐私信息填写在 secrets 中，需要用时再调用可以起到保护隐私的作用。

3.1.5 完整代码

```yaml
name: 'news_push'

on:
  push:
  schedule:
    - cron: '0 22 * * *'


jobs:
  build:
    runs-on: ubuntu-latest

    steps:
    - uses: actions/checkout@v2
      with:
        presist-credentials: false
        fetch-depth: 0
    - name: Set up Python 3.8
      uses: actions/setup-python@v2
      with:
        python-version: '3.8'
    - name: Install dependencies
      run: |
        python -m pip install --upgrade pip
        pip install -r ./requirements.txt
    - name: Run my script
      run: |
        python ./my_script.py




    - name: 'Send mail'
      uses: dawidd6/action-send-mail@master
      with:
        server_address: smtp.qq.com
        server_port: 465
        username: ${{ secrets.MAIL_USERNAME }}
        password: ${{ secrets.MAIL_PASSWORD }}
        subject: 来自onlyourmiracle的news每日通知快送

        body: file://text.html
        to: ${{ secrets.MAIL_LIST }}
        from: GitHub Actions
        content_type: text/html
```

图 3.6 完整代码

第四章 提交代码

4.1 将所有代码提交至仓库等待运行

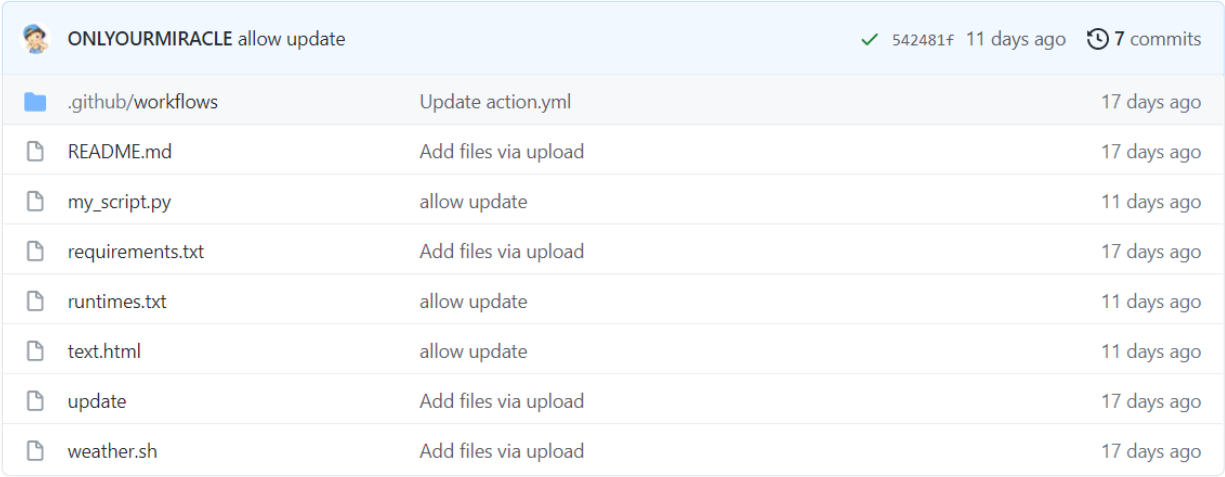

图 4.1 所有代码文件

4.2 运行界面

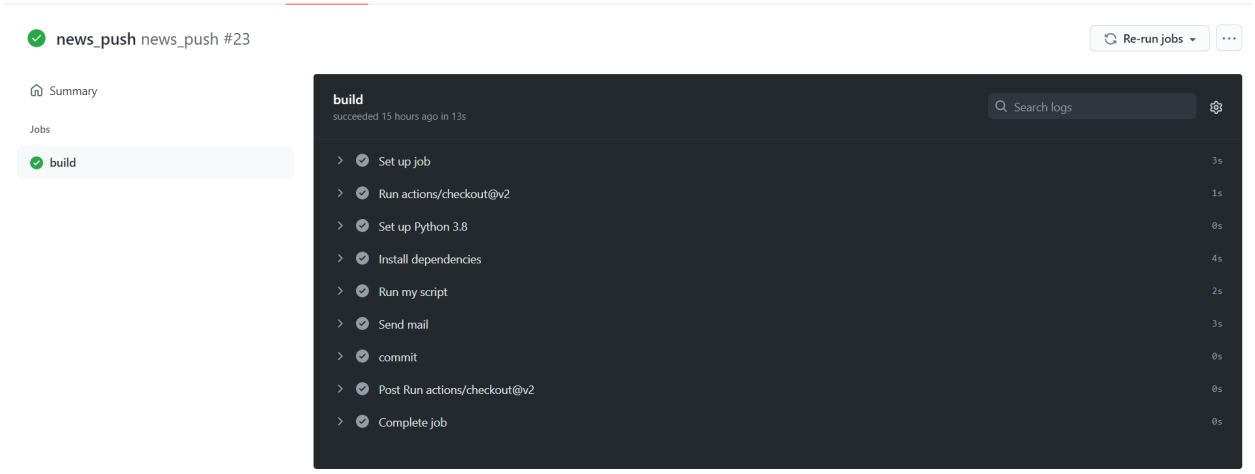

图 4.2 运行界面

4.3 运行后效果

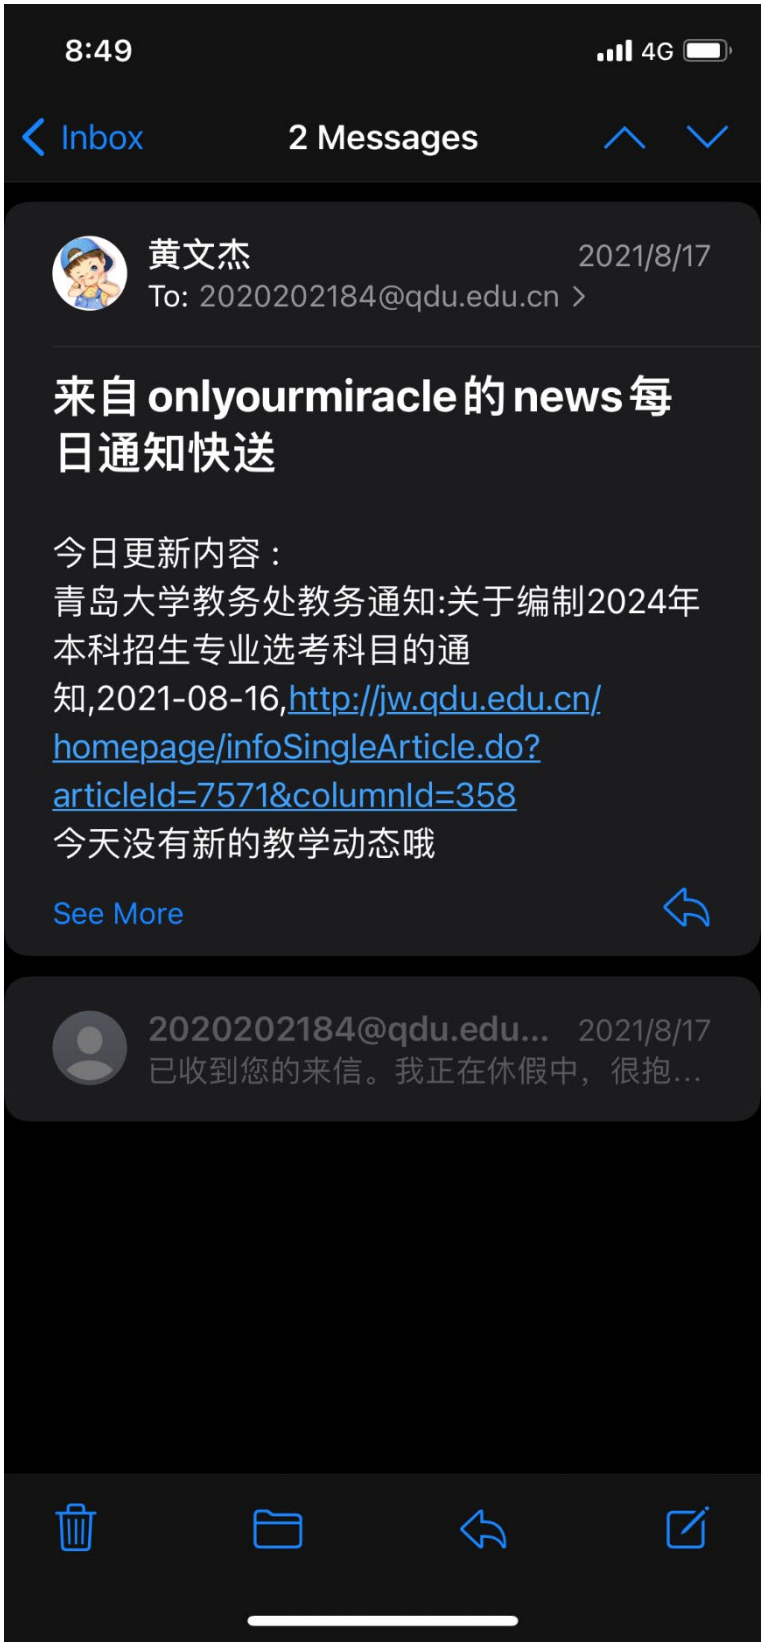

图 4.3 运行效果 A

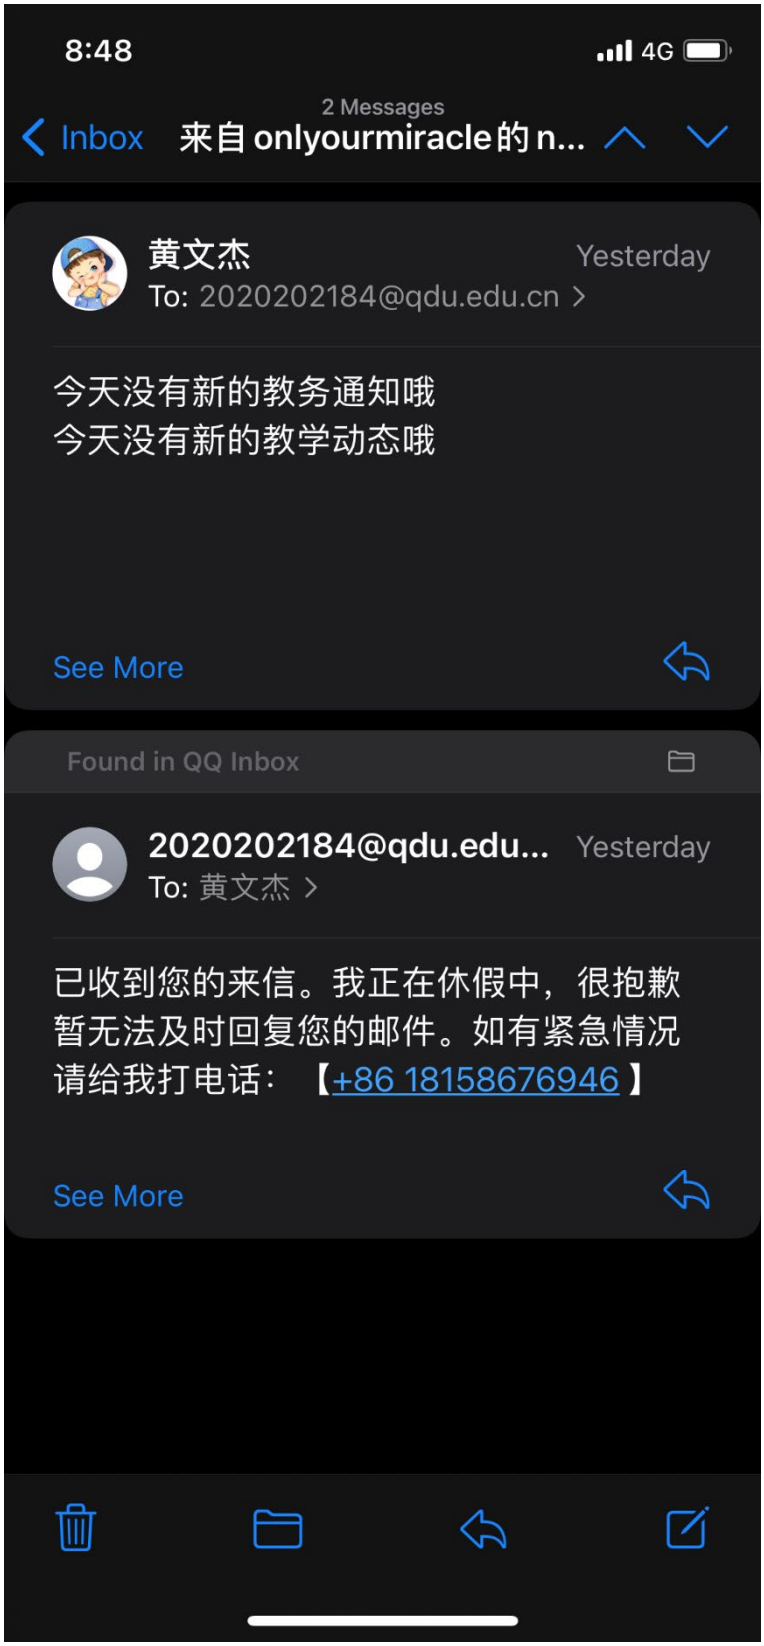
8:48
4G
2 Messages
Inbox
来自 onlyourmiracle 的 n...
黄文杰
Yesterday
To: 2020202184@qdu.edu.cn
今天没有新的教务通知哦
今天没有新的教学动态哦
See More
Found in QQ Inbox
2020202184@qdu.edu...
Yesterday
To: 黄文杰
已收到您的来信。我正在休假中，很抱歉
暂无法及时回复您的邮件。如有紧急情况
请给我打电话：【+86 18158676946】
See More

图 4.4 运行效果 B

第五章 总结与展望

本文基于 GitHub Actions 满足相应条件下运行一系列命令的持续集成服务，结合 Python 网络爬虫代码，设计并实现了基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱服务，这里对本文的工作内容做出以下几点总结：

（1）系统地学习了 Python 网络爬虫的知识，熟悉了各类库的使用，主要包括请求网页源码的 requests、urllib 库，分析网页源码的 lxml 库等，结合之前积累的 datetime 库等相关知识，最后实现了能够爬取青岛大学教务通知及教学动态并判断是否具有时效性的功能。

（2）通过参考相关项目经验[2]，根据自身需求，配置 GitHub Actions 服务，最后实现了基于 GitHub Actions 定时爬取青岛大学教务通知及教学动态并发送至目标邮箱服务。

本文还有一些不足的地方：

（1）从功能上来讲，本文所实现的定时发送邮件功能比较简单，只实现了爬取青岛大学教务通知及教学动态这一块内容，后期可以在此基础上增加其它内容，比如说爬取其它所关注的内容。

（2）信息展示页面还可以优化。

参考文献

[1]薛琳兰. 基于大数据技术的电商推荐系统的设计与实现[D].青岛大学,2020.
[2]Lincest(2020)newsexpress[Source code].
https://github.com/Lincest/newsexpress.